# **BIG DATA**

PROYECTO FINAL

Samuel Porcel Rodríguez

New Technology School Tokio.





SAMUEL PORCEL RODRÍGUEZ

RESPONSABLE DEL DESARROLLO DEL PROYECTO FINAL

Fecha: 13/11/2024

# ÍNDICE

1.	DESARROLLO	2
	1.1. Categorizar según el tipo de dato y su estructura	2
	1.2. Cassandra	
	1.3. Dataframe de PySpark	
	1.4. Análisis descriptivo, matriz de correlación y logaritmo	





## **DESARROLLO**

### **PROYECTO FINAL: BIG DATA**

#### Documento técnico

#### TAREAS:

1. Categorizar según el tipo de dato y su estructura:

	Nombre del campo	Tipo de dato
1.	Activity Period	Numérico discreto
2.	Operating Airline	Categórico nominal
3.	Operating Airline IATA Code	Categórico nominal
4.	Published Airline	Categórico nominal
5.	Published Airline IATA Code	Categórico nominal
6.	GEO Summary	Categórico nominal
7.	GEO Region	Categórico nominal
8.	Activity Type Code	Categórico nominal
9.	Price Category Code	Categórico nominal
10.	Terminal	Categórico ordinal
11.	Boarding Area	Categórico ordinal
12.	Passenger Count	Numérico discreto
13.	Adjusted Activity Type Code	Categórico nominal
14.	Adjusted Passenger Count	Numérico discreto
15.	Year	Numérico discreto
16.	Month	Categórico ordinal





#### 2. Cassandra:

```
Crear espacio y tabla:
CREATE KEYSPACE statistics
WITH replication = {'class':'SimpleStrategy', 'replication_factor': '1'}
AND durable_writes = TRUE;
CREATE TABLE statistics.traffic (
"Activity Period" int,
"Operating Airline" text,
"Operating Airline IATA Code" text,
"Published Airline" text,
"Published Airline IATA Code" text,
"GEO Summary" text,
"GEO Region" text,
"Activity Type Code" text,
"Price Category Code" text,
"Terminal" text,
"Boarding Area" text,
"Passenger Count" int,
"Adjusted Activity Type Code" text,
"Adjusted Passenger Count" int,
"Year" int,
"Month" text,
PRIMARY KEY ("Operating Airline", "Year")
) WITH CLUSTERING ORDER BY ("Year" ASC);
```



#### • Insertar datos en las columnas de la tabla:

```
Insertar datos en las columnas de la tabla:

Insertar datos en la tabla:

Insertar datos en las columnas de la tabla:

Insertar datos en la tabla:

Insertar da
```

- Verificar la importación visualizando la tabla:
   SELECT \* FROM statistics.traffic;
- a) RECUPERAR TODOS LOS REGISTROS DE LA AEROLÍNEA "AIR CHINA": SELECT \* FROM statistics.traffic WHERE "Operating Airline" = 'Air China' ALLOW FILTERING;
- b) RECUPERAR TODOS LOS VUELOS DE LA COMPAÑÍA "AIR BERLÍN" EMBARCADOS POR LA PUERTA "G": SELECT \* FROM statistics.traffic WHERE "Operating Airline" = 'Air Berlin' AND "Boarding Area" = 'G' ALLOW FILTERING;





#### 3. Dataframe de Pyspark:





#### 4. Análisis descriptivo, matriz de correlación y logaritmo:

```
ANÁLISIS DESCRIPTIVO
      Media del número de pasajeros según la región, categoria de precio y el mes
      Desviación estandar del número de pasajeros según la región, categoria de precio y el mes
  [15] df_region = df.groupBy('GEO Region').agg (F.std('Passenger Count').alias('std_passenger_count')).show()
           · Matriz de correlación en el resultado
   [16] # Transformo todas las variables para poder calcular la correlacion. Crear nuevas columnas operating airline_indexer = StringIndexer(inputCol="Operating Airline", outputCol="Operating Airline Index") df = operating_airline_indexer.fit(df).transform(df)
             geo_summary_indexer = StringIndexer(inputCol="GEO Summary", outputCol="GEO Summary Index")
df = geo_summary_indexer.fit(df).transform(df)
             geo_region_indexer = StringIndexer(inputCol="GEO Region", outputCol="GEO Region Index")
df = geo_region_indexer.fit(df).transform(df)
             activity\_type\_code\_indexer = StringIndexer(inputCol="Activity Type\_Code", outputCol="Activity Type\_Code\_indexer-fit(df).transform(df)
             price_category_code_indexer = StringIndexer(inputCol="Price Category Code", outputCol="Price Category Code Index")
df = price_category_code_indexer.fit(df).transform(df)
             terminal\_indexer = StringIndexer(inputCol="Terminal", outputCol="Terminal Index") \\ df = terminal\_indexer.fit(df).transform(df)
             boarding\_area\_indexer = StringIndexer(inputCol="Boarding\_Area", outputCol="Boarding\_Area\_Index")\\ df = boarding\_area\_indexer.fit(df).transform(df)
[19] # Generar matriz de correlación y calcular la correlación entre todas las variables númericas
numeric_cols = ['Operating Airline Index', 'GEO Summary Index', 'GEO Region Index', 'Activity Type Code Index', 'Price Category Code Index',
'Terminal Index', 'Boarding Area Index', 'Passenger Count', 'Year', 'month_numero']
             for col1 in numeric_cols:
   for col2 in numeric_cols:
      corr_value = df.stat.corr(col1, col2)
      print(f"Correlación entre (col1) y {col2}: {corr_value}")
```



```
    Algoritmo: Árbol de decisión

                                                                                                                                                                                                                                                                     ↑ ↓ © □ ‡ ᡚ □ :
   from pyspark.sql import SparkSession
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.evaluation import RepressionEvaluator
from pyspark.ml.regression import GBTRegressor
             # Crear una sesión de Spark
spark = SparkSession.builder.appName("Air Traffic Passenger Prediction").getOrCreate()
            # Transformar columnas a indice
operating airline indexer - StringIndexer(inputCol="Operating Airline", outputCol="Operating Airline Index")
df = operating_airline_indexer.fit(df).transform(df)
            published_airline_indexer = StringIndexer(inputCol="Published Airline", outputCol="Published Airline Index")
df = published_airline_indexer.fit(df).transform(df)
            GEO_summary_indexer = StringIndexer(inputCol="GEO Summary", outputCol="GEO Summary Index")
df = GEO_summary_indexer.fit(df).transform(df)
            activity type_code_indexer = StringIndexer(inputCol="Activity Type Code", outputCol="Activity Type Code Index")

df = activity type_code_indexer_fit(df)_transform(df)
        df = operating_airline_indexer.fit(df).transform(df)
                                                                                                                                                                                                                                                                     ↑ ↓ e> □ ‡ 🗓 🔟 :
0
         published_airline_indexer = StringIndexer(inputCol="Published Airline", outputCol="Published Airline Index")
df = published_airline_indexer.fit(df).transform(df)
         activity_type_code_indexer = StringIndexer(inputCol="Activity Type Code", outputCol="Activity Type Code Index")
df = activity_type_code_indexer.fit(df).transform(df)
        price_category_code_indexer = StringIndexer(inputCol="Price Category Code", outputCol="Price Category Code Index")
df = price_category_code_indexer.fit(df).transform(df)
        terminal_indexer = StringIndexer(inputCol="Terminal", outputCol="Terminal Index")
df = terminal_indexer.fit(df).transform(df)
        boarding_area_indexer = StringIndexer(inputCol="Boarding Area", outputCol="Boarding Area Index")

df = boarding_area_indexer.fit(df).transform(df)
        adjusted_activity_type_code_indexer = StringIndexer(inputCol="Adjusted Activity Type Code", outputCol="Adjusted Activity Type Code Index")

df = adjusted_activity_type_code_indexer.fit(df).transform(df)
        month_indexer = StringIndexer(inputCol="Month", outputCol="Month Index")
df = month_indexer.fit(df).transform(df)
                                                                                                                                                                                                                                                                     ↑ ↓ ⊖ 🗏 🗘 🔟 :
    ## Modifican tipos de datos

## df withColumn('Activity Period', df['Activity Period'].cast('float'))

## df withColumn('Published Airline Index', df['Operating Airline Index'].cast('float'))

## df withColumn('Published Airline Index', df['Published Airline Index'].cast('float'))

## df withColumn('GEO Summary Index', df['Fublished Airline Index'].cast('float'))

## df withColumn('Price Category Code Index', df['Activity Type Code Index'].cast('float'))

## df withColumn('Price Category Code Index', df['Price Category Code Index'].cast('float'))

## df withColumn('Price Category Code Index', df['Price Category Code Index'].cast('float'))

## df df withColumn('Price Category Code Index', df['Boarding Area Index'].cast('float'))

## df df withColumn('Boarding Area Index', df['Boarding Area Index'].cast('float'))

## df df withColumn('Agisted Activity Type Code Index', df['Adjusted Activity Type Code Index'].cast('float'))

## df withColumn('Month Index', df['Month Index'].cast('float'))
       # Crear la columna 'features' utilizando VectorAssembler
va = VectorAssembler(inputCols=['Activity Period','Operating Airline Index', 'Published Airline Index', 'GEO Summary Index','Activity Type Code Index',

'Price Category Code Index', 'Terminal Index', 'Boarding Area Index', 'Year', 'Adjusted Activity Type Code Index', 'Month Index'], output
      # Dividir los datos en entrenamiento y prue
train, test = df.randomSplit([0.8, 0.2])
      # Definir el modelo de regresión basado en árboles de decisión
rf = GBTRegressor(featuresCol='features', labelCol='Passenger Count', maxIter=100)
```

